

Anteproyecto Minería de Datos / Mateo Bustamante Moreno

Estimación del redshift fotométrico en cuásares mediante machine learning usando la base de datos Skyserver del SDSS.

Introducción

Los cuásares son objetos extremadamente luminosos asociados a núcleos galácticos activos y constituyen una herramienta importante para estudiar la estructura y evolución del universo. Una de sus propiedades más relevantes es el redshift, ya que permite estimar su distancia cosmológica y analizar su distribución en el tiempo. Sin embargo, la medición espectroscópica del redshift no siempre está disponible para todos los objetos observados, lo que limita algunos estudios astronómicos.

En este contexto, el uso de técnicas de machine learning ofrece una alternativa interesante para estimar el redshift a partir de propiedades fotométricas y otras características observables. Este proyecto propone trabajar con un catálogo astronómico público de cuásares, consultar y extraer datos mediante ADQL, aplicar técnicas de aprendizaje automático para predecir el redshift de los objetos y evaluar el desempeño de los algoritmos comparando con los datos reales. (No se mencionan a detalle las técnicas de machine learning para la creación y evaluación de modelos, ya que todavía no hemos visto esto en el curso).

Este trabajo es pertinente tanto desde el punto de vista astronómico como metodológico, ya que permite integrar herramientas de consulta de bases de datos, análisis estadístico y machine learning en un problema real de interés científico.

Este problema también sirve como punto de partida para aprender del tema y adaptarse a este tipo de análisis usando machine learning. Una idea muy interesante (y que realmente era la primera idea de proyecto pero era un poco más compleja) es hacer la predicción de redshift para los GRB, ya que aproximadamente el 30 % de los GRB tienen la medición del redshift, por lo que en un futuro, con un reentrenamiento y después de aprender más sobre los modelos, se puede hacer una predicción de estas importantes características.

Objetivo general

Desarrollar modelos de machine learning para estimar el redshift de cuásares a partir de datos fotométricos obtenidos por el SDSS, utilizando ADQL para la consulta de datos y herramientas de análisis para interpretar el comportamiento de la muestra.

Objetivos específicos

- Consultar y descargar una muestra de cuásares desde una base de datos astronómica mediante ADQL.
- Limpiar y preparar la base de datos para su análisis, seleccionando variables útiles para el modelo.
- Construir un modelo para predecir el redshift.
- Entrenar y evaluar el modelo para analizar su desempeño.
- Analizar la importancia de las variables fotométricas en la predicción del redshift.
- Interpretar los resultados desde el punto de vista astronómico y discutir posibles limitaciones del modelo.

Metodología

Se elegirá un catálogo público de cuásares y se extraerán los datos mediante consultas ADQL. Se buscarán variables como redshift, magnitudes fotométricas y, en lo posible, colores derivados de las bandas observacionales.

Se eliminarán registros incompletos, se revisarán valores atípicos y se seleccionarán las variables más relevantes para el análisis y comenzar con la creación del modelo.

Se medirá el desempeño y posteriormente se compararán las predicciones con los valores reales del redshift.

Por último, se estudiará qué variables tienen mayor peso en el modelo y se discutirá su relación con la física de los cuásares. Finalmente, se presentarán las limitaciones del enfoque y posibles mejoras futuras.

Cronograma

Entrega: 1 de junio

- **Semana 1:** Selección del catálogo, búsqueda bibliográfica, definición de variables y consulta de datos mediante ADQL. Limpieza, organización y preprocesamiento del conjunto de datos.
- **Semana 2:** Creación del modelo y entrenamiento.
- **Semana 3:** Evaluar el modelo hasta que pueda coincidir con la realidad.
- **Semana 4:** Interpretación física y redacción final del proyecto.