

Anteproyecto: Caracterización de la física de cuásares mediante eigenspectra

Sofía Lorena Casallas Beltrán¹

¹*Instituto de Física, Universidad de Antioquia U de A, calle 70 No. 52-21, Medellín, Colombia*

(Dated: May 2, 2026)

I. INTRODUCCIÓN

Los cuásares son núcleos galácticos activos ultra-luminosos impulsados por la acreción de materia en agujeros negros supermasivos. Debido a que son visibles hasta corrimientos al rojo de $z > 7$ constituyen herramientas cosmológicas esenciales para estudiar la expansión del universo. Sin embargo, su gran diversidad fenoménica, la cual se refleja en las variaciones de líneas de emisión e índices espectrales, se tiene que no son una clase homogénea, sino que existen subpoblaciones con distintas historias de acreción, cuya caracterización representa un desafío.

Con el Sloan Digital Sky Survey (SDSS) que tiene aproximadamente 700.000 espectros de cuásares se afronta un difícil análisis manual resulta inviable. Este proyecto propone un flujo de trabajo automatizado que integra el acceso programático a bases de datos remotas, el preprocesamiento de datos y la aplicación de algoritmos de aprendizaje automático. El objetivo es implementar un pipeline reproducible que permita clasificar y predecir parámetros físicos de forma eficiente, aplicando técnicas aprendidas en el curso.

El SDSS pone a disposición varias fuentes de donde tomar los datos de los cuásares que podrían usarse en este proyecto: el DR16Q que es las siglas de SDSS Quasar Catalog, Data Release 16, el cual es el de referencia principal, con más de 750.000 cuásares confirmados espectroscópicamente, también se cuenta con los espectros individuales en formato FITS, el cual es accesible usando Astroquery a partir del identificador de `specobjid` presente en los catálogos.

II. MARCO TEÓRICO

Para la extracción de datos se usará el servidor CasJobs del SDSS usando SQL sobre la base de datos devolviendo seleccionado las columnas de interés, a partir de esto, se automatiza desde la terminal la descarga de los espectros individuales (FITS) utilizando Astroquery, desde la base de datos de SIMBAD y VizieR.

Con estos datos, al tener resoluciones y altos órdenes de flujo, se realizará un procesamiento de los datos

utilizando la reducción de dimensionalidad por componentes principales (PCA), el cual encuentra una base ortonormal en el espacio de flujos que maximiza la varianza. Los primeros componentes principales que se encuentren serán los eigenspectrales los cuales capturan los patrones de variabilidad más relevantes de la muestra, comprimiendo cada espectro en un vector sin pérdida significativa de información física.

Sobre el espacio de baja dimensión definido anteriormente con los coeficientes de PCA se aplicarán dos algoritmos de agrupamiento: K-Means, este particiona la muestra en K grupos asignando cada objeto al centroide más cercano en el espacio euclidiano, y GMM, que generaliza K-Means modelando cada grupo como una distribución gaussiana multivariante con media y covarianza propias.

Luego se utilizará un método de aprendizaje supervisado llamado Random Forest, que se basa en la construcción de un conjunto de árboles de decisión entrenados sobre submuestras aleatorias de los datos y características. El Random Forest se usará para predecir el *redshift* fotométrico z_{phot} partiendo desde los coeficientes obtenidos en el PCA y los colores fotométricos del catálogo, usando como etiqueta el *redshift* espectroscópico z_{spec} . La importancia de cada característica permitirá identificar cuáles componentes principales concentran la mayor información sobre el desplazamiento al rojo, conectando el resultado estadístico con la interpretación física.

III. RESULTADOS ESPERADOS

- Un repositorio de GitHub documentado con notebooks reproducibles para cada etapa del flujo, desde la consulta SQL hasta el modelo de Random Forest.
- Una muestra limpia de cuásares del SDSS-DR16 extraída mediante consultas SQL/ADQL.
- La identificación de subpoblaciones espectrales utilizando K-Means y GMM.
- Un modelo de Random Forest capaz de predecir el *redshift* espectroscópico con buenas métricas