

Anteproyecto: Minería de Datos en Astronomía

Caracterización de Brazos en Galaxias Espirales mediante aprendizaje automatico y Datos Fotométricos del SDSS

Ruby Daniela Contreras, Universidad de Antioquia

Mayo de 2026

1. Introducción

La morfología de las galaxias es una ventana fundamental para entender la evolución del Universo. En el ámbito de la radioastronomía, la definición de los brazos galácticos está ligada a la densidad de gas neutro (HI) y la cinemática que amplía de cierta manera la vision del tamaño de las galazias. Sin embargo, con la posibilidad de grandes proyectos ópticos como el *Sloan Digital Sky Survey* (SDSS), es posible complementar esta visión mediante la minería de grandes volúmenes de datos fotométricos.

Este proyecto propone utilizar técnicas de aprendizaje automático (Machine Learning) para identificar y cuantificar la presencia de estructuras espirales en galaxias, utilizando parámetros morfológicos tabulares para automatizar una tarea que tradicionalmente requería inspección visual humana.

2. Planteamiento del Problema

La clasificación morfológica manual de millones de objetos astronómicos es ineficiente. El problema reside en la dificultad de definir cuantitativamente qué constituye un brazo galáctico basándose únicamente en parámetros numéricos, como el índice de Sersic, radios de Stokes o colores. El reto de este proyecto es determinar si un modelo de minería de datos puede aprender a distinguir estas estructuras basándose en datos de catálogos ya existentes y cómo estas características se relacionan con la descripción física de los brazos vista en radioastronomía.

3. Objetivos

3.1. Objetivo General

Implementar un modelo de clasificación basado en minería de datos para identificar galaxias espirales y caracterizar la prominencia de sus brazos utilizando el catálogo SDSS DR17.

3.2. Objetivos Específicos

- Realizar consultas optimizadas mediante SQL/ADQL para extraer parámetros morfológicos y fotométricos de la base de datos del SDSS.

- Aplicar técnicas de preprocesamiento y limpieza de datos astronómicos utilizando las librerías **Pandas** y **Astropy**.
- Ejecutar un análisis de componentes principales para reducir la dimensionalidad y entender qué variables físicas explican mejor la estructura espiral.
- Entrenar y validar un algoritmo de clasificación para predecir la morfología galáctica basándose en el proyecto *Galaxy Zoo* una iniciativa de ciencia ciudadana que ha permitido la categorización morfológica detallada de millones de galaxias del SDSS mediante el consenso de voluntarios. La relevancia de este conjunto de datos radica en que proporciona la *ground truth* (verdad de campo) necesaria para el aprendizaje supervisado; esto permite que el algoritmo de Machine Learning correlacione variables numéricas abstractas (como el índice de concentración o los colores fotométricos) con estructuras físicas reales, como la presencia de brazos espirales o barras, garantizando así una interpretación astronómica robusta de los resultados.

4. Metodología

El proyecto se dividirá en cuatro fases alineadas de cierta manera con lo aprendido en el curso, y lo aun faltante:

1. **Fase de Adquisición:** Uso de **Astroquery** y lenguajes de consulta (SQL) para acceder a los servidores de SDSS. Se seleccionará una muestra de galaxias con magnitudes, rojos al azul (redshifts) y parámetros de forma.
2. **Fase de Procesamiento Científico (Mes 3):** Manejo de archivos FITS y tablas astrométricas. Se utilizará el ecosistema **Astropy** para realizar correcciones de coordenadas y cálculos de distancias.
3. **Fase de Minería y Modelado (Mes 4):**
 - *Aprendizaje No Supervisado:* Implementación de PCA y K-means para explorar agrupamientos naturales en los datos.
 - *Aprendizaje Supervisado:* Entrenamiento de un modelo de **Random Forest** para clasificar las galaxias. Se evaluará la importancia de las variables para determinar qué parámetros definen físicamente a los brazos.
4. **Fase de Interpretación:** Discusión de resultados desde una perspectiva astrofísica, comparando los hallazgos ópticos con la teoría de ondas de densidad de los brazos galácticos.

5. Recursos Técnicos

- **Plataforma:** Google Colaboratory.
- **Lenguaje:** Python 3.x.

- **Librerías principales:** Scikit-Learn (ML), Astropy (unidades y FITS), Pandas (dataframes) y Matplotlib (visualización).
- **Datos:** SDSS *SkyServer Search* (Data Release 17).

6. Resultados Esperados

Se espera desarrollar un flujo de trabajo (*pipeline*) reproducible que clasifique galaxias espirales con una precisión superior al 60 %. Asimismo, se busca obtener una lista de los parámetros fotométricos que más influyen en la detección de brazos, proporcionando un puente cuantitativo entre la morfología óptica y los estudios de astronomía.

7. Bibliografía

- Silva-Villa, E. (2024). *Minería de Datos en Astronomía*. Recuperado de: <https://esilvavilla.github.io/MineriaDatosweb/intro.html>.
- SDSS SkyServer Documentation: <https://skyserver.sdss.org/dr17/>