

Anteproyecto de Proyecto

Minería de Datos en Astronomía

Detección Automática de Exoplanetas mediante LightGBM a partir
de Curvas de Luz del Telescopio Espacial Kepler

Autor: **Sebastian Mejia Marin**

Asignatura: Minería de Datos en Astronomía

Índice

1. Planteamiento del Problema	1
2. Objetivos	1
2.1. Objetivo General	1
2.2. Objetivos Específicos	1
3. Marco Teórico	1
3.1. Tránsito Planetario	1
3.2. Datos MAST y <i>Kepler</i>	2
3.3. <i>LightGBM</i> (Light Gradient Boosting Machine)	2
4. Metodología (Workflow)	2
5. Cronograma de Actividades (6 semanas)	2
6. Recursos Necesarios	2
7. Referencias Bibliográficas	3
8. Resultados Esperados	3

1. Planteamiento del Problema

Los telescopios espaciales como *Kepler* han generado una cantidad masiva de datos (más de 200,000 estrellas observadas durante años). La detección manual de eventos de tránsito planetario es inviable por su volumen, y los métodos tradicionales como BLS (*Box-Least Squares*) producen muchas señales falsas positivas (binarias eclipsantes, actividad estelar), lo que ralentiza el proceso científico.

Pregunta de Investigación: ¿Es posible entrenar un modelo de clasificación supervisado basado en *LightGBM* que, a partir de características estadísticas extraídas de las curvas de luz, logre distinguir automáticamente entre exoplanetas reales y falsos positivos con alta precisión?

2. Objetivos

2.1. Objetivo General

Desarrollar e implementar un *pipeline* de minería de datos en Python que automatice la detección de exoplanetas a partir de curvas de luz del telescopio *Kepler*, utilizando el algoritmo *LightGBM* para clasificar señales de tránsito.

2.2. Objetivos Específicos

1. Consultar y descargar de MAST las curvas de luz de la misión *Kepler*, tanto de objetos confirmados como de falsos positivos.
2. Implementar un proceso de limpieza y normalización de las series de tiempo astronómicas.
3. Extraer un conjunto de características relevantes (*features*) de cada curva de luz, como profundidad del tránsito, duración, relación señal/ruido (SNR) y métricas de periodicidad.
4. Entrenar y optimizar un modelo de clasificación *LightGBM* con manejo de datos desbalanceados.
5. Evaluar el rendimiento del modelo mediante validación cruzada y métricas robustas (AUC-ROC, Precisión y Recall).

3. Marco Teórico

3.1. Tránsito Planetario

Fenómeno en el que un planeta pasa por delante de su estrella anfitriona, bloqueando una pequeña fracción de su luz. La curva de luz resultante muestra una caída característica y periódica en el flujo estelar.

3.2. Datos MAST y *Kepler*

El *Mikulski Archive for Space Telescopes* (MAST) alberga los datos de las misiones *Kepler* y *TESS*. El catálogo *Kepler Objects of Interest* (KOI) contiene señales clasificadas como planetas confirmados, candidatos o falsos positivos, lo que proporciona una etiqueta de verdad fundamental para el aprendizaje supervisado.

3.3. *LightGBM* (Light Gradient Boosting Machine)

Algoritmo de *boosting* basado en árboles de decisión que destaca por su alta eficiencia computacional y precisión. Es particularmente útil para manejar grandes volúmenes de datos y características heterogéneas. Además, permite gestionar el desbalance de clases (más falsos positivos que planetas) mediante parámetros como `is_unbalance` o `scale_pos_weight`.

4. Metodología (Workflow)

El proyecto se estructurará en 6 fases secuenciales:

1. **Ingesta de Datos (Python + Astroquery):** Uso del módulo `astroquery.mast` para consultar y descargar curvas de luz FITS de la misión *Kepler* directamente desde MAST.
2. **Preprocesamiento (Astropy + Lightkurve):** Limpieza de valores atípicos (*outliers*), corrección del ruido instrumental y normalización de la serie temporal.
3. **Ingeniería de Características:** Creación de un *dataset* tabular extrayendo de cada curva de luz métricas estadísticas y morfológicas (media, varianza, *skewness*, profundidad del tránsito, duración estimada, SNR).
4. **División de Datos:** Separación en conjuntos de entrenamiento (80 %) y prueba (20 %), asegurando estratificación para preservar la proporción de clases.
5. **Entrenamiento del Modelo (LightGBM):** Implementación con ajuste de hiperparámetros (`GridSearchCV`). Configuración de `is_unbalance=True` o ajuste manual de pesos para mitigar el impacto del desbalance.
6. **Evaluación y Muestreo de Resultados:** Cálculo de matriz de confusión, curvas ROC-AUC y análisis de las características más importantes para la clasificación.

5. Cronograma de Actividades (6 semanas)

6. Recursos Necesarios

- **Computacional:** Acceso a Internet, máquina con capacidad para ejecutar Python (CPU suficiente, no se requiere GPU).

Cuadro 1: Cronograma tentativo por semanas

Fase	S1	S2	S3	S4	S5	S6
1. Consulta y descarga de datos (MAST/Kepler)	X					
2. Preprocesamiento y limpieza de curvas de luz	X	X				
3. Ingeniería de características y dataset		X	X			
4. Implementación del modelo LightGBM			X	X		
5. Optimización de hiperparámetros y validación				X	X	
6. Análisis de resultados y documentación final					X	X

- **Software:** Python 3.8+, Jupyter Notebook o IDE (VS Code), Git para control de versiones.
- **Librerías Python:** `astroquery`, `lightcurve`, `lightgbm`, `scikit-learn`, `numpy`, `pandas`, `matplotlib`.
- **Datos:** NASA Exoplanet Archive y MAST (acceso público sin autenticación).

7. Referencias Bibliográficas

1. NASA Exoplanet Archive. *Kepler Objects of Interest (KOI) Table*. Caltech/IPAC. <https://exoplanetarchive.ipac.caltech.edu/>
2. LightGBM Documentation. *Handling Imbalanced Data*. Microsoft.
3. Lightcurve Documentation. *Kepler and TESS time series analysis in Python*. <https://docs.lightcurve.org/>
4. Repositorio de referencia: `oliversoctopus/koi-exoplanet-detection` (GitHub). <https://github.com/oliversoctopus/koi-exoplanet-detection>

8. Resultados Esperados

Se espera obtener un clasificador capaz de detectar patrones de tránsito planetario con una precisión mínima del 90 % (basado en referencias similares), reduciendo significativamente la cantidad de candidatos falsos positivos que deban ser verificados manualmente por astrónomos. El modelo permitirá acelerar el proceso de descubrimiento de nuevos exoplanetas en archivos históricos y futuros (*TESS*, *PLATO*).